GUIA TÉCNICO

Avaliação, Segurança e Privacidade em PLN

Propósito — Conteúdo didático autoral — notas técnicas e exemplos independentes. Material de apoio histórico não é reproduzido neste PDF.

Como utilizar — Leia as explicações, execute os exemplos no ambiente indicado e consulte os notebooks correspondentes.

ROTEIRO DO DOCUMENTO

1. Fundamentos e objetivo
2. Modelo e escolhas metodológicas
3. Receitas Python reproduzíveis
4. Interpretação e limitações
5. Exercícios de aplicação
6. Checklist de qualidade

01 | O problema e seu contexto

Avaliação, Segurança e Privacidade em PLN é estudado como técnica computacional, com hipóteses explícitas, dados de demonstração e análise crítica dos resultados.

Cuidados metodológicos

Avalie relevância, robustez e exposição indevida em exemplos separados. Testes sintéticos não substituem avaliação com dados representativos.

02 | Fundamentos e modelo

Objetivos de aprendizagem

- Projetar avaliações de recuperação, classificação e geração.
- Reconhecer prompt injection e risco de privacidade.
- Documentar versões, custos, limites e testes de regressão.

Fundamentos conceituais

A avaliação de PLN deve medir a tarefa real: classificação exige métricas por classe; recuperação utiliza precisão e recall em k, MRR ou nDCG; geração precisa de checagem de fidelidade, utilidade e adequação. Uma avaliação automática isolada não comprova segurança ou precisão factual. Conteúdo obtido de terceiros é dado não confiável, mesmo quando parece instrução operacional.

Modelo matemático e interpretação

Precisão@k = (número de relevantes no top-k)/k. Recall@k = (número de relevantes no top-k)/(total de documentos relevantes). Um teste de regressão compara versões do sistema sob um conjunto estável de perguntas representativas.

Estudo guiado

Pergunta de investigação: como demonstrar o conceito central com um exemplo pequeno, auditável e reproduzível?

Nas células seguintes, inspecione as entradas, execute os procedimentos e explique com suas próprias palavras o resultado. Ao trocar o texto ou o parâmetro, observe se o comportamento permanece coerente. Esses resultados são ilustrações pedagógicas, não benchmarks.

Implementação reproduzível

O código abaixo usa textos sintéticos ou bibliotecas locais. Não executa downloads nem acessa APIs externas. Exemplos opcionais só rodam quando a dependência já está disponível; a ausência deles não interrompe o notebook.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Interpretação guiada: verifique se o resultado corresponde à fórmula e à hipótese discutidas. Anote o que muda com a entrada e quais conclusões não podem ser generalizadas a partir deste exemplo.

Exercícios orientados

1. Compreensão: explique qual informação o método preserva e qual descarta. Relacione a resposta com os objetivos do capítulo.
2. Experimento: altere uma frase e um parâmetro do código. Registre a diferença e uma hipótese explicativa.
3. Avaliação crítica: descreva uma situação em que a técnica geraria uma resposta inadequada. Proponha uma mitigação.
4. Transferência: conecte o conceito a uma disciplina anterior e identifique o que não precisa ser revisto.

Resolução comentada (diretriz de resposta): o método representa somente um recorte do fenômeno linguístico; mudanças de entrada alteram a saída segundo a regra estudada. Uma boa análise identifica perda de informação, contexto e risco de generalização. Para a resposta específica, justifique com os valores efetivamente obtidos na execução acima.

Erros comuns, limitações e boas práticas

Não armazenar senhas ou PII em notebooks. Nunca executar instruções recuperadas de documentos como comandos. Citar proveniência, licenças e limites; tratar mudanças de modelos e APIs como alterações que precisam de revalidação.

- Separe demonstração de produção: datasets sintéticos não demonstram generalização.
- Registre versões das dependências e parâmetros; não inclua credenciais no notebook.
- Consulte a documentação oficial antes de adaptar códigos históricos de 2021.

03 | Cookbook Python

Métricas de recuperação

```
relevantes = {'doc1','doc3'}
recuperados = ['doc1','doc2']
p = len(set(recuperados)&relevantes)/len(recuperados)
r = len(set(recuperados)&relevantes)/len(relevantes)
print({'precision':p, 'recall':r})
```

Proteção de logs

```
def mascarar_email(t):
    import re
    return re.sub(r'\b[\w.+-]+@[\w.-]+\.[A-Za-z]{2,}\b','[EMAIL]',t)
print(mascarar_email('Contato: ana@exemplo.com'))
```

04 | Interpretação e limites

Avalie relevância, robustez e exposição indevida em exemplos separados. Testes sintéticos não substituem avaliação com dados representativos.

05 | Exercícios com respostas orientadoras

1. Altere uma entrada ou parâmetro e descreva o comportamento observado.

Resposta orientadora: mantenha os demais elementos constantes, documente a mudança e explique qual resultado deveria variar pela hipótese escolhida.

2. Cite uma situação em que a técnica falha ou transmite confiança excessiva.

Resposta orientadora: identifique domínio, idioma, quantidade de dados, formato da entrada, possíveis erros sistemáticos e um teste que exponha o limite.

3. Escreva um teste de sanidade que possa ser executado antes de analisar os resultados.

Resposta orientadora: estabeleça forma, tipo, dimensões ou invariantes esperados para os dados, e uma observação que invalidaria a conclusão.

06 | Referências e consulta

Material construído a partir de exercícios autorais da biblioteca, com o conteúdo histórico utilizado apenas como apoio privado. Documentação técnica: Python (docs.python.org), scikit-learn (scikit-learn.org), NLTK (nltk.org), spaCy (spacy.io).

Portfólio GitHub: https://github.com/eduardojr-pereira/data-science-portfolio

Site pessoal: https://eduardo-pereira.webflow.io/