Atenção e Transformers

Q/K/V, máscara e arquitetura

ATENÇÃO

Q
Consultas: posição que procura informação.

K
Chaves: vetores comparados às consultas.

V
Valores: informação combinada.

EQUAÇÃO

Escalada
$A(Q,K,V)=\text{softmax}(QK^T/\sqrt{d_k})V$

Softmax
Normalizar por linha e usar estabilidade numérica.

Máscara
Logits proibidos recebem $-\infty$ antes do softmax.

CAUSALIDADE

Causal
Token t não vê posições maiores que t.

Padding
Tokens de enchimento ficam mascarados.

Validação
Soma por linha = 1 nas posições válidas.

MULTI-HEAD

Cabeças
Projeções Q/K/V independentes.

Concat
Saídas por cabeça são combinadas.

Posição
Atenção isolada não codifica ordem.

TRANSFORMER

Bloco
Atenção + residual + normalização.

FFN
Rede feed-forward por posição.

Arquiteturas
Encoder, decoder ou variantes híbridas.

CUSTOS

Complexidade
Atenção plena requer $O(T^2)$ scores.

Limite
Atenção não equivale ao Transformer completo.

Teste
Checar máscara causal em matriz pequena.