Atenção, Transformers e tendências em Deep Learning

Resumo de consulta · capítulo 20/20

CONCEITOS-CHAVE

Objetivo
Derivar atenção escalada e entender as diferenças entre arquiteturas recorrentes e Transformers.

Fundamento 1
Atenção mede relações entre tokens por similaridades de consultas e chaves, normalizadas por softmax, e combina valores.

Fundamento 2
Atenção causal bloqueia posições futuras.

Fundamento 3
Transformers acrescentam positional encoding, normalização, resíduos e feed-forward.

Fundamento 4
Aprofundamento aplicado de PLN está na área de Processamento de Linguagem Natural.

Pré-requisito
Conferir os eixos, as hipóteses e os tipos de entrada antes de executar.

RELAÇÕES E IMPLEMENTAÇÃO

Relação essencial
$\text{Attention}(Q,K,V)=\text{softmax}(QK^T/\sqrt{d_k})V$

Operação 1
```
import numpy as np
```

Operação 2
```
q=np.array([[1.,0.],[0.,1.]]);k=q.copy();v=np.array([[2.,1.],[0.,3.]])
```

Operação 3
```
scores=q@k.T/np.sqrt(q.shape[-1]);p=np.exp(scores-scores.max(axis=
```

Laboratório aplicado
Atenção com Q/K/V, máscara causal e softmax estável é o componente; Transformer inclui blocos residuais e posição.

Trecho aplicado
```
import numpy as np
```

TESTES, ARMADILHAS E REVISÃO

Exercício
Por que dividir o produto QK^T por $\sqrt{d_k}$?

Solução
Para controlar a escala dos logits, reduzindo saturação da softmax quando a dimensão cresce.

Limite técnico
Confundir demonstração matemática com validação de um modelo de produção.

Validação
Compare a fórmula com os resultados e confira dimensões e métricas.

Experimento neural
Opcional: TensorFlow/Keras dependem de instalação e execução local.

Referência
Consulte numpy.org/doc, keras.io/guides e a documentação do notebook.