Backpropagation, MLP e XOR

Regra da cadeia em rede multicamada

MLP

Forward
$h = \varphi(W_1 x + b_1)$; $\hat{y} = g(W_2 h + b_2)$

Loss
$L(\hat{y}, y)$ mede desajuste.

Backward
Propaga gradientes da saída às entradas.

CADEIA

Saída
$\delta_2 = \partial L / \partial z_2$

Oculta
$\delta_1 = (W_2^\top \delta_2) \odot \varphi'(z_1)$

Pesos
$\partial L / \partial W_1 = \delta_1 x^\top$

XOR

Tabela
(0,0)→0; (0,1)→1; (1,0)→1; (1,1)→0

Limite
Perceptron linear não modela XOR.

Solução
MLP com camada oculta não linear.

GRADIENTES

Checagem
Comparar derivada analítica à numérica.

Saturação
Sigmoid pode enfraquecer gradientes.

Forma
Verifique dimensões em produtos matriciais.

TREINO

Seed
Fixar para comparar experimentos.

Épocas
Acompanhar trajetória da perda.

Diagnóstico
Verificar previsões nas quatro entradas.

DISTINÇÕES

NumPy
Permite entender derivação passo a passo.

Keras
Calcula gradientes via autodiff.

Limite
Treino simples não comprova robustez.