CNNs na prática

Classificação e métricas em imagens

ENTRADAS

MNIST
Dígitos em escala de cinza.

Fashion-MNIST
Itens de vestuário, 28×28.

CIFAR-10
Imagens coloridas, 32×32.

ARQUITETURA

Bloco
Conv2D → ReLU → MaxPooling.

Cabeça
Flatten ou GlobalAveragePooling → Dense.

Saída
10 logits para dez classes.

PREPARAÇÃO

Escala
Normalizar pixels de forma consistente.

Forma
(batch, H, W, canais)

Partição
Teste mantido intocado durante seleção.

TREINO

Loss
SparseCategoricalCrossentropy(from_logits=True).

Métrica
Accuracy e confusão por classe.

Baseline
Comparar classificador simples no mesmo teste.

LIMITES

Dados sintéticos
Teste de pipeline; não mede desempenho real.

Generalização
Domínio diferente pode degradar resultados.

Custo
CNN pode exigir acelerador.

DIAGNÓSTICO

Curvas
Plotar train/val loss e accuracy.

Erros
Inspecionar exemplos classificados incorretamente.

Reprodutibilidade
Seeds e versões de dados.