Fundamentos matemáticos de convolução e CNNs

Resumo de consulta · capítulo 13/20

CONCEITOS-CHAVE

Objetivo
Calcular saídas de convolução, padding, stride, pooling e parâmetros.

Fundamento 1
Filtros compartilham pesos espacialmente.

Fundamento 2
Em imagens, convoluções detectam padrões locais; camadas profundas combinam representações.

Fundamento 3
Dimensão espacial depende de kernel, padding, dilatação e stride.

Fundamento 4
O que a função aprende?

Pré-requisito
Conferir os eixos, as hipóteses e os tipos de entrada antes de executar.

RELAÇÕES E IMPLEMENTAÇÃO

Relação essencial
$out = \lfloor (n + 2p - d(k-1) - 1)/s \rfloor + 1$

Operação 1

```
import numpy as np
```

Operação 2

```
im=np.arange(25).reshape(5,5)
```

Operação 3

```
k=np.array([[1.,0.],[-1.,0.]])
```

Laboratório aplicado
Correlação cruzada, stride, padding e dilatação determinam o mapa de características; checar shapes e convenções.

Trecho aplicado

```
import numpy as np
```

TESTES, ARMADILHAS E REVISÃO

Exercício
Quantos parâmetros tem Conv2D com kernel 3×3, 3 canais de entrada e 16 filtros, com bias?

Solução
3×3×3×16 + 16 = 448 parâmetros.

Limite técnico
Confundir demonstração matemática com validação de um modelo de produção.

Validação
Compare a fórmula com os resultados e confira dimensões e métricas.

Experimento neural
Opcional: TensorFlow/Keras dependem de instalação e execução local.

Referência
Consulte numpy.org/doc, keras.io/guides e a documentação do notebook.