Interpretabilidade em visão

Saliência e limites de explicação

SALIÊNCIA

Definição
Gradiente da saída em relação à entrada.

Fórmula
$S_{ij} = |\partial score_c / \partial x_{ij}|$

Objeto
Destaca sensibilidade local, não causalidade.

TÉCNICAS

Saliency
Gradiente absoluto por pixel.

Grad-CAM
Agrega gradientes de mapas convolucionais.

Oclusão
Mede mudança ao ocultar regiões.

DETECÇÃO

Classificação
Prediz classe para imagem inteira.

Detecção
Prediz caixas + classes + escores.

IoU
Área de interseção / união de duas caixas.

VALIDAÇÃO

Sanity check
Compare com pesos/labels aleatorizados.

Ruído
Mapas podem ser instáveis.

Métrica
Não confundir destaque com acurácia.

ARMADILHAS

Atalho
Modelo pode usar fundo/artefatos.

Causalidade
Explicação visual não prova mecanismo.

Viés
Avalie por subgrupo e domínio.

IMPLEMENTAÇÃO

NumPy
Diferença finita aproxima gradiente.

TF
GradientTape para derivada autêntica.

Resultado
Normalizar mapa apenas para visualização.