Perdas, gradientes e otimização

Critério objetivo e atualização

PERDAS

MSE
$(1/n)\ \Sigma(\hat{y}_i - y_i)^2$

MAE
$(1/n)\ \Sigma|\hat{y}_i - y_i|$

Cross-entropy
$-\Sigma\ y_k \log p_k$

DERIVADAS

Gradiente
Direção de maior aumento local da perda.

Descida
$\theta \leftarrow \theta - \eta\nabla\theta L$

Regra da cadeia
Combina derivadas camada por camada.

OTIMIZADORES

SGD
Atualiza com gradiente do minibatch.

Momentum
Acumula direção das atualizações.

Adam
Momentos adaptativos com correção de viés.

CONTROLE

Learning rate
Alto: diverge; baixo: convergência lenta.

Batch size
Afeta ruído, memória e dinâmica.

Épocas
Passagens completas pelo conjunto de treino.

VERIFICAÇÃO

Diferença finita
$[L(\theta+\varepsilon) - L(\theta-\varepsilon)] / (2\varepsilon)$

Compare
Erro relativo com gradiente analítico.

Alerta
Escala de features muda as derivadas.

PRÁTICA

Curvas
Compare perda treino/validação.

Explosão
Considere gradient clipping.

Platô
Investigue taxa, inicialização e dados.