Redes recorrentes, LSTM e GRU

Resumo de consulta · capítulo 18/20

CONCEITOS-CHAVE

Objetivo
Explicar estados ocultos, dependências temporais e controle por portas.

Fundamento 1
RNNs processam sequências com estado oculto compartilhado.

Fundamento 2
O gradiente pode desaparecer/explodir em sequências longas; LSTM e GRU usam portas para reter e atualizar informação.

Fundamento 3
Shapes e máscaras distinguem sequências de comprimentos variáveis.

Fundamento 4
O que a função aprende?

Pré-requisito
Conferir os eixos, as hipóteses e os tipos de entrada antes de executar.

RELAÇÕES E IMPLEMENTAÇÃO

Relação essencial
$h_t=\tanh(W_x x_t+W_h h_{(t-1)}+b)$

Operação 1
import numpy as np

Operação 2
rng=np.random.default_rng(0)

Operação 3
x=np.array([.2,.3,.4]);h=0.;wx=.8;wh=.35

Laboratório aplicado
Estados recorrentes, gradientes no tempo e portas de memória ajudam a explicar RNN/LSTM/GRU e suas limitações.

Trecho aplicado
import numpy as np

TESTES, ARMADILHAS E REVISÃO

Exercício
Por que LSTM pode superar RNN simples em sequências longas?

Solução
Suas portas e caminho de memória ajudam a preservar informação e reduzir o desaparecimento de gradientes.

Limite técnico
Confundir demonstração matemática com validação de um modelo de produção.

Validação
Compare a fórmula com os resultados e confira dimensões e métricas.

Experimento neural
Opcional: TensorFlow/Keras dependem de instalação e execução local.

Referência
Consulte numpy.org/doc, keras.io/guides e a documentação do notebook.