GUIA TÉCNICO

CNNs na prática: MNIST, Fashion-MNIST e CIFAR

Capítulo 14/20 · Fundamentos, experiência reproduzível e interpretação

PROPÓSITO E OBJETIVOS

- Construir uma CNN compacta e distinguir domínios de imagens.
- Relacionar a técnica à sua função de perda, representação e protocolo de avaliação.
- Explicar limitações e formular um teste reprodutível.

MAPA DE ESTUDO

1. Fundamentação do método
2. Expressões e hipóteses
3. Experimento essencial executável
4. Laboratório aplicado e limitações
5. Exercício e verificações

01 FUNDAMENTAÇÃO CONCEITUAL

MNIST é relativamente simples e em escala de cinza; Fashion-MNIST e CIFAR exigem representações progressivamente mais complexas. Normalizar pixels com os dados corretos e respeitar canais (H,W,C). Treinos reais ficam no laboratório opcional.

Fonte histórica de apoio: notas do curso original, consultadas apenas como referência de contexto; as explicações e exemplos desta edição são independentes.

Questões críticas: quais pressupostos são necessários? O que a função aprende? Qual métrica indica utilidade real? Que tipo de vazamento ou má interpretação invalidaria a conclusão?

02 MATEMÁTICA E DIMENSÕES

Expressão esquemática: X∈R^(B,H,W,C)

A expressão acima resume a relação central. Para a derivação, identifique dimensões, hipóteses e operações; não interprete notação compacta como uma implementação completa.

LEITURA CRÍTICA DO CAPÍTULO

Uma CNN só demonstra aprendizado quando rótulos correspondem a padrões e o desempenho é medido fora do treino.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

03 EXPERIMENTO ESSENCIAL

Código extraído do notebook revisado. Execute a célula completa no JupyterLab; as quebras visuais abaixo não substituem o arquivo executável.

```
import numpy as np
rng=np.random.default_rng(15)
X=rng.random((8,28,28,1),dtype=np.float32)
flat=X.reshape(len(X),-1)
print('Batch de imagens:',X.shape,'flatten:',flat.shape)
assert flat.shape==(8,784)
```

INTERPRETAÇÃO

Compare o resultado obtido com a formulação matemática. Confirme shapes, escala e hipótese de modelagem. Um experimento sintético valida uma operação, não substitui avaliação em dados reais. Ao treinar modelos, separe dados e ajuste transformações apenas no treino; preserve um conjunto final de teste.

04 LABORATÓRIO APLICADO

Laboratório aplicado revisado — Classificador de imagens sintéticas com padrão aprendível

Uma CNN só demonstra aprendizado quando rótulos correspondem a padrões e o desempenho é medido fora do treino.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

```
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score
rng=np.random.default_rng(14);  ↪
    n=260;X=np.zeros((n,12,12),dtype=np.float32);y=np.repeat([0,1],n//2)
for i in range(n):
    if y[i]==0:X[i,:,4:6]=1.0
    else:X[i,4:6,:]=1.0
    X[i]+=rng.normal(0,.22,size=(12,12))
idx=rng.permutation(n);X,y=X[idx],y[idx]
Xt,Xe,yt,ye=train_test_split(X.reshape(n,-1),y,test_size=.25,stratify=y,random_state=14)
m=LogisticRegression(max_iter=300).fit(Xt,yt)
a=accuracy_score(ye,m.predict(Xe))
print('Baseline linear para listras horizontais/verticais:',round(a,3));assert a>.8
```

Este experimento testa padrões com baseline linear. CNN verdadeira deve usar amostras de treino e teste separadas e métricas reais, não ruído com rótulos arbitrários.

Checklist: conferir entradas e saídas, sementes, inexistência de uso dos dados de teste durante ajuste e distinção entre uma demonstração sintética e desempenho em aplicações reais.

05 EXERCÍCIO E SOLUÇÃO COMENTADA

Por que não usar Flatten imediatamente em imagens grandes?

Resposta: Porque perde estrutura espacial e eleva muito a quantidade de parâmetros em camadas densas.

LIMITAÇÕES E BOAS PRÁTICAS

- Confundir ajuste no treino com generalização para dados não vistos.
- Reportar somente uma métrica ou uma execução aleatória.
- Ignorar shape, tipo de variável e convenção do backend.
- Executar exemplos com pesos baixados sem registrar versão, licença e procedência.

• Confundir demonstração matemática com validação de um modelo de produção.

VERIFICAÇÃO LOCAL

Execute Reiniciar kernel e executar todas as células. Registre versões do Python e das dependências, confira shapes e métricas e diferencie os laboratórios opcionais dos exemplos NumPy/scikit-learn.

Validação posterior (13/11/2026): notebooks 14 a 20 executados com TensorFlow CPU; opcionais 01 a 13 não integralmente revalidados.

REFERÊNCIAS TÉCNICAS

NumPy: numpy.org/doc · scikit-learn: scikit-learn.org/stable/user_guide.html · Keras: keras.io/guides · TensorFlow: tensorflow.org/guide

REVISÃO DIDÁTICA · CAPÍTULO 14

Treinamento CNN e validade do experimento

1. Conceito, escopo e interpretação

Uma CNN aprende filtros locais sobre imagens; porém um classificador logístico aplicado a pixels achatados e um experimento sintético não equivalem a treinar uma CNN real em MNIST, Fashion-MNIST ou CIFAR.

2. Formalização e exemplo resolvido

> Conv2D(16,3x3) sobre RGB contém (3*3*3+1)*16=448 parâmetros com bias. Com padding=same e stride=1, imagem 28x28 mantém dimensões espaciais antes de pooling.

3. Relação com o notebook e experimento

Reproduza o classificador de padrões sintéticos do notebook. Se executar o laboratório opcional CNN, registre arquitetura, epochs, validation accuracy, curva de loss e um baseline comparável.

4. Limitações e erros frequentes

Evite afirmar desempenho nos datasets clássicos sem treiná-los. Dados sintéticos fáceis podem superestimar a capacidade de generalização para imagens reais.

5. Exercício comentado

O que distingue Conv2D de uma Dense sobre a imagem achatada? Compartilhamento espacial de pesos e conectividade local em Conv2D.

6. Ampliação conceitual do guia

Uma CNN explora estrutura espacial por kernels compartilhados e pooling; a avaliação exige dados independentes e uma métrica coerente com o problema. MNIST, Fashion-MNIST e CIFAR diferem em dificuldade e não são benchmarks intercambiáveis.

7. Orientação de estudo e validação

O notebook inclui experimento sintético de classificação de imagens e laboratório TensorFlow opcional. Distinguir padrões sintéticos de benchmarks reais é essencial: resultado alto em figuras artificiais não comprova generalização em CIFAR. Registre histórico de treinamento e baseline.

8. Exercício adicional de fixação

Exercício: por que uma LogisticRegression com pixels achatados é um baseline útil? Resposta: mede desempenho sem usar a estrutura convolucional.

Verificação: execute o notebook homônimo no ambiente apropriado; registre versões, shapes, sementes e métricas. Laboratórios Keras opcionais não foram executados durante esta revisão documental.

Abrir notebook do capítulo no repositório

LABORATÓRIO COMPLEMENTAR · CAPÍTULO 14

Laboratório CNN — imagem sintética com padrão

Implementação ilustrativa / formalização

```
import numpy as np
from keras import Sequential, Input, layers
rng = np.random.default_rng(42)
X = rng.normal(0,.1,size=(240,16,16,1)).astype('float32')
y = np.arange(240)%2
for i in range(240):
    if y[i]==0: X[i, 4:12, 7:9, 0] += 1
    else: X[i, 7:9, 4:12, 0] += 1
model=Sequential([Input(shape=(16,16,1)),layers.Conv2D(8,3,activation='relu'),
                  layers.MaxPooling2D(),layers.Flatten(),layers.Dense(1,activation='sigmoid')])
model.compile(optimizer='adam',loss='binary_crossentropy',metrics=['accuracy'])
model.fit(X[:180],y[:180],epochs=5,verbose=0)
print(model.evaluate(X[180:],y[180:],verbose=0))
```

Interpretação e limites

O alvo é distinguir padrões sintéticos de traços verticais/horizontais; não há MNIST, Fashion-MNIST ou CIFAR neste exemplo. O conjunto de teste é separado antes do ajuste, mas amostras sintéticas simples não demonstram robustez a imagens reais.

Como verificar

Execute o código no ambiente indicado pelo notebook. Se depender de Keras/TensorFlow, registre versões e resultados reais; esta revisão não afirma execução do laboratório.

Referência: notebook do mesmo capítulo em 07_deep_learning (GitHub).