GUIA TÉCNICO

Data augmentation e avaliação robusta em visão

Capítulo 15/20 · Fundamentos, experiência reproduzível e interpretação

PROPÓSITO E OBJETIVOS

- Escolher transformações plausíveis e impedir vazamento entre imagens relacionadas.
- Relacionar a técnica à sua função de perda, representação e protocolo de avaliação.
- Explicar limitações e formular um teste reprodutível.

MAPA DE ESTUDO

1. Fundamentação do método
2. Expressões e hipóteses
3. Experimento essencial executável
4. Laboratório aplicado e limitações
5. Exercício e verificações

01 FUNDAMENTAÇÃO CONCEITUAL

Transformações de treino precisam preservar o rótulo. Flips podem ser inadequados em números e medicina; crops podem eliminar o objeto. Em dados com múltiplas imagens por pessoa, dividir por indivíduo antes de augmentar.

Fonte histórica de apoio: notas do curso original, consultadas apenas como referência de contexto; as explicações e exemplos desta edição são independentes.

Questões críticas: quais pressupostos são necessários? O que a função aprende? Qual métrica indica utilidade real? Que tipo de vazamento ou má interpretação invalidaria a conclusão?

02 MATEMÁTICA E DIMENSÕES

Expressão esquemática: X_aug=T(X_treino)

A expressão acima resume a relação central. Para a derivação, identifique dimensões, hipóteses e operações; não interprete notação compacta como uma implementação completa.

LEITURA CRÍTICA DO CAPÍTULO

Augmentation só pode agir sobre o conjunto de treino, após separação por grupo/indivíduo quando houver dependência.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

03 EXPERIMENTO ESSENCIAL

Código extraído do notebook revisado. Execute a célula completa no JupyterLab; as quebras visuais abaixo não substituem o arquivo executável.

```
import numpy as np
im=np.arange(16).reshape(4,4)
flip=np.fliplr(im);noise=np.random.default_rng(7).normal(0,.01,size=im.shape)
print('Original:',im[0].tolist(),'flip horizontal:',flip[0].tolist(),'ruído ↪
    média:',round(noise.mean(),4))
assert np.array_equal(flip[:,::-1],im)
```

INTERPRETAÇÃO

Compare o resultado obtido com a formulação matemática. Confirme shapes, escala e hipótese de modelagem. Um experimento sintético valida uma operação, não substitui avaliação em dados reais. Ao treinar modelos, separe dados e ajuste transformações apenas no treino; preserve um conjunto final de teste.

04 LABORATÓRIO APLICADO

Laboratório aplicado revisado — Separação por grupo antes da transformação de treino

Augmentation só pode agir sobre o conjunto de treino, após separação por grupo/indivíduo quando houver dependência.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

```
import numpy as np
from sklearn.model_selection import GroupShuffleSplit
rng=np.random.default_rng(15);img=rng.normal(size=(24,8,8));groups=np.repeat(np.arange(8),  ↪
    3)
split=GroupShuffleSplit(n_splits=1,test_size=.25,random_state=15)
tr,te=next(split.split(img,groups=groups))
assert not (set(groups[tr]) & set(groups[te]))
aug=img[tr]+rng.normal(0,.01,size=img[tr].shape)
print('Grupos treino:',len(set(groups[tr])),'teste:',len(set(groups[te])),'imagens  ↪
    aumentadas:',aug.shape[0])
```

Aumentar somente imagens do treino depois da divisão; testar se as transformações preservam o significado da classe.

Checklist: conferir entradas e saídas, sementes, inexistência de uso dos dados de teste durante ajuste e distinção entre uma demonstração sintética e desempenho em aplicações reais.

05 EXERCÍCIO E SOLUÇÃO COMENTADA

Por que augmentação deve ocorrer após separar treino e teste?

Resposta: Para evitar versões transformadas da mesma imagem aparecendo em conjuntos diferentes.

LIMITAÇÕES E BOAS PRÁTICAS

- Confundir ajuste no treino com generalização para dados não vistos.
- Reportar somente uma métrica ou uma execução aleatória.
- Ignorar shape, tipo de variável e convenção do backend.
- Executar exemplos com pesos baixados sem registrar versão, licença e procedência.
- Confundir demonstração matemática com validação de um modelo de produção.

VERIFICAÇÃO LOCAL

Execute Reiniciar kernel e executar todas as células. Registre versões do Python e das dependências,

confira shapes e métricas e diferencie os laboratórios opcionais dos exemplos NumPy/scikit-learn.

Validação posterior (13/11/2026): notebooks 14 a 20 executados com TensorFlow CPU; opcionais 01 a 13 não integralmente revalidados.

REFERÊNCIAS TÉCNICAS

NumPy: numpy.org/doc · scikit-learn: scikit-learn.org/stable/user_guide.html · Keras: keras.io/guides · TensorFlow: tensorflow.org/guide

REVISÃO DIDÁTICA · CAPÍTULO 15

Augmentation sem vazamento entre grupos

1. Conceito, escopo e interpretação

Data augmentation cria variações plausíveis nos dados de treino para melhorar robustez. Primeiro divida por grupos/origens, depois gere transformações apenas no treino; do contrário, versões quase idênticas podem vazar para o teste.

2. Formalização e exemplo resolvido

> Para um grupo original g, imponha g pertence exatamente a um entre treino, validação e teste. Nenhuma transformação T(x_g) deve cruzar a fronteira entre grupos.

3. Relação com o notebook e experimento

No notebook use GroupShuffleSplit e verifique interseção vazia entre identificadores de origem dos splits. Compare desempenho em teste natural e em perturbações de intensidade controlada.

4. Limitações e erros frequentes

Transformações devem preservar o rótulo. Rotação ou espelhamento podem trocar significado em letras, sinais ou imagens médicas; nunca aplique augmentation indiscriminadamente.

5. Exercício comentado

Por que duas imagens derivadas da mesma foto não devem ficar em treino e teste? Porque tornam o teste dependente de informação já vista.

6. Ampliação conceitual do guia

Aumento de dados gera transformações de exemplos de treino para melhorar robustez, mas variantes da mesma origem não devem aparecer em treino e teste. O split por grupo deve ocorrer ANTES de qualquer transformação dependente da amostra original.

7. Orientação de estudo e validação

O notebook ilustra GroupShuffleSplit. Compare métricas por grupos e avalie transformações plausíveis: espelhamento pode ser válido para objetos naturais, mas incorreto quando orientação carrega rótulo, como em certos exames e símbolos.

8. Exercício adicional de fixação

Exercício: por que uma imagem rotacionada no teste e a original no treino causam viés? Resposta: são amostras correlacionadas da mesma origem.

Verificação: execute o notebook homônimo no ambiente apropriado; registre versões, shapes, sementes e métricas. Laboratórios Keras opcionais não foram executados durante esta revisão documental.

Abrir notebook do capítulo no repositório