GUIA TÉCNICO

Interpretabilidade visual e detecção de objetos

Capítulo 17/20 · Fundamentos, experiência reproduzível e interpretação

PROPÓSITO E OBJETIVOS

- Entender saliência, mapas de ativação e distinguir classificação de detecção.
- Relacionar a técnica à sua função de perda, representação e protocolo de avaliação.
- Explicar limitações e formular um teste reprodutível.

MAPA DE ESTUDO

1. Fundamentação do método
2. Expressões e hipóteses
3. Experimento essencial executável
4. Laboratório aplicado e limitações
5. Exercício e verificações

01 FUNDAMENTAÇÃO CONCEITUAL

Mapas de saliência mostram sensibilidade local e não causalidade. Detecção de objetos combina classe e localização, frequentemente por caixas delimitadoras; segmentação estima regiões por pixel. Avaliação exige IoU, precisão e recall por limiar.

Fonte histórica de apoio: notas do curso original, consultadas apenas como referência de contexto; as explicações e exemplos desta edição são independentes.

Questões críticas: quais pressupostos são necessários? O que a função aprende? Qual métrica indica utilidade real? Que tipo de vazamento ou má interpretação invalidaria a conclusão?

02 MATEMÁTICA E DIMENSÕES

Expressão esquemática: IoU=área(A∩B)/área(A∪B)

A expressão acima resume a relação central. Para a derivação, identifique dimensões, hipóteses e operações; não interprete notação compacta como uma implementação completa.

LEITURA CRÍTICA DO CAPÍTULO

Mapas de saliência localizam sensibilidades de predição, mas não estabelecem relação causal; separar interpretação de detecção.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

03 EXPERIMENTO ESSENCIAL

Código extraído do notebook revisado. Execute a célula completa no JupyterLab; as quebras visuais abaixo não substituem o arquivo executável.

```
def iou(a,b):
 x1=max(a[0],b[0]);y1=max(a[1],b[1]);x2=min(a[2],b[2]);y2=min(a[3],b[3])
 inter=max(0,x2-x1)*max(0,y2-y1)
 area=lambda q:(q[2]-q[0])*(q[3]-q[1])
 return inter/(area(a)+area(b)-inter)
print('IoU:',round(iou((0,0,2,2),(1,1,3,3)),3))
assert abs(iou((0,0,2,2),(1,1,3,3))-1/7)<1e-9
```

INTERPRETAÇÃO

Compare o resultado obtido com a formulação matemática. Confirme shapes, escala e hipótese de modelagem. Um experimento sintético valida uma operação, não substitui avaliação em dados reais. Ao treinar modelos, separe dados e ajuste transformações apenas no treino; preserve um

conjunto final de teste.

04 LABORATÓRIO APLICADO

Laboratório aplicado revisado — Mapa de saliência numérica com gradientes de entrada

Mapas de saliência localizam sensibilidades de predição, mas não estabelecem relação causal; separar interpretação de detecção.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

```
import numpy as np
img=np.array([[.1,.2,.3],[.4,.5,.6],[.7,.8,.9]],dtype=float)
weights=np.array([[0.,1.,0.],[0.,2.,0.],[0.,1.,0.]])
def score(x):return float(np.sum(x*weights))
h=1e-5
saliency=np.zeros_like(img)
for i in range(img.shape[0]):
 for j in range(img.shape[1]):
    p=img.copy();q=img.copy();p[i,j]+=h;q[i,j]-=h
    saliency[i,j]=(score(p)-score(q))/(2*h)
assert np.allclose(saliency,weights,atol=1e-8)
print('Saliência numérica:\n',saliency)
print('Saliência é sensibilidade local, NÃO uma explicação causal.')
```

Para um modelo real use gradientes da pontuação da classe em relação à imagem, comparando com abordagens e perturbações alternativas.

Checklist: conferir entradas e saídas, sementes, inexistência de uso dos dados de teste durante ajuste e distinção entre uma demonstração sintética e desempenho em aplicações reais.

05 EXERCÍCIO E SOLUÇÃO COMENTADA

Uma heatmap de saliência prova causalidade?

Resposta: Não; destaca regiões sensíveis ao modelo, não necessariamente evidência causal.

LIMITAÇÕES E BOAS PRÁTICAS

- Confundir ajuste no treino com generalização para dados não vistos.
- Reportar somente uma métrica ou uma execução aleatória.
- Ignorar shape, tipo de variável e convenção do backend.
- Executar exemplos com pesos baixados sem registrar versão, licença e procedência.
- Confundir demonstração matemática com validação de um modelo de produção.

VERIFICAÇÃO LOCAL

Execute Reiniciar kernel e executar todas as células. Registre versões do Python e das dependências, confira shapes e métricas e diferencie os laboratórios opcionais dos exemplos NumPy/scikit-learn.

Validação posterior (13/11/2026): notebooks 14 a 20 executados com TensorFlow CPU; opcionais 01 a 13 não integralmente revalidados.

REFERÊNCIAS TÉCNICAS

NumPy: numpy.org/doc · scikit-learn: scikit-learn.org/stable/user_guide.html · Keras: keras.io/guides · TensorFlow: tensorflow.org/guide

REVISÃO DIDÁTICA · CAPÍTULO 17

Saliência, sensibilidade e explicação

1. Conceito, escopo e interpretação

Um mapa de saliência estima sensibilidade local da saída em relação à entrada. O gradiente pode apontar pixels influentes, mas saliência não é explicação causal e depende de escala, saturação e escolha do alvo.

2. Formalização e exemplo resolvido

Saliencia(x)=abs(d score_c(x)/dx). Um gradiente numérico em pixel i pode usar [score(x+h e_i)-score(x-h e_i)]/(2h).

3. Relação com o notebook e experimento

No notebook gere o mapa numérico e compare resultados para h diferentes. Inspecione normalização, colorização e coerência entre imagem, classe escolhida e mapa apresentado.

4. Limitações e erros frequentes

Gradientes pequenos podem ocorrer por saturação, não por irrelevância causal. Detecção de objetos exige localização e métricas próprias; saliência isolada não implementa detector.

5. Exercício comentado

Um mapa altamente brilhante comprova que o modelo “olhou” apenas aquele pixel? Não; trata-se de sensibilidade local em torno da entrada dada.

6. Ampliação conceitual do guia

Mapas de saliência baseados em gradientes aproximam sensibilidade da saída às entradas, não causalidade. Gradientes podem ser ruidosos, saturados e instáveis; visualizações devem ser verificadas com controles e perturbações.

7. Orientação de estudo e validação

O notebook cria mapa de saliência numérica e o exporta como PNG. Compare regiões destacadas com uma referência simples, documente normalização e escala de cores e evite afirmar que um pixel destacado foi causalmente responsável pela predição.

8. Exercício adicional de fixação

Exercício: um mapa de gradiente explica o funcionamento inteiro do modelo? Resposta: não; mostra uma sensibilidade local sob a entrada escolhida.

Verificação: execute o notebook homônimo no ambiente apropriado; registre versões, shapes, sementes e métricas. Laboratórios Keras opcionais não foram executados durante esta revisão documental.

Abrir notebook do capítulo no repositório