GUIA TÉCNICO | 19

Modelos sequenciais: séries temporais e sentimentos

Capítulo 19/20 · Fundamentos, experiência reproduzível e interpretação

PROPÓSITO E OBJETIVOS

- Construir janelas temporais sem vazamento e diferenciar modelagem temporal de classificação de textos.
- Relacionar a técnica à sua função de perda, representação e protocolo de avaliação.
- Explicar limitações e formular um teste reprodutível.

MAPA DE ESTUDO

1. Fundamentação do método
2. Expressões e hipóteses
3. Experimento essencial executável
4. Laboratório aplicado e limitações
5. Exercício e verificações

01 FUNDAMENTAÇÃO CONCEITUAL

Janelas dependem de horizonte, contexto e data de corte. Em séries financeiras, retornos não são previsíveis apenas por suavidade aparente; comparar com baseline ingênuo e evitar extrapolação de evidência. Em sentimento, tokenização e embeddings são requisitos (ver área de Processamento de Linguagem Natural).

Fonte histórica de apoio: notas do curso original, consultadas apenas como referência de contexto; as explicações e exemplos desta edição são independentes.

Questões críticas: quais pressupostos são necessários? O que a função aprende? Qual métrica indica utilidade real? Que tipo de vazamento ou má interpretação invalidaria a conclusão?

02 MATEMÁTICA E DIMENSÕES

Expressão esquemática: $X_t=(y_{t-k},\ldots,y_{t-1})$

A expressão acima resume a relação central. Para a derivação, identifique dimensões, hipóteses e operações; não interprete notação compacta como uma implementação completa.

LEITURA CRÍTICA DO CAPÍTULO

Corte cronológico, janelas somente com passado e baseline ingênuo são necessários antes de avaliar LSTM para séries.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

03 EXPERIMENTO ESSENCIAL

Código extraído do notebook revisado. Execute a célula completa no JupyterLab; as quebras visuais abaixo não substituem o arquivo executável.

```
import numpy as np
serie=np.arange(25,dtype=float)
janela=4;horizonte=1
X=np.array([serie[i:i+janela] for i in range(len(serie)-janela-horizonte+1)])
y=np.array([serie[i+janela+horizonte-1] for i in range(len(X))])
corte=round(.75*len(X));print('Treino:',X[:corte].shape,'teste:',X[corte:].shape,'primeiro
    alvo:',y[0]);assert y[0]==4.
```

INTERPRETAÇÃO

Compare o resultado obtido com a formulação matemática. Confirme shapes, escala e hipótese de modelagem. Um experimento sintético valida uma operação, não substitui avaliação em dados

reais. Ao treinar modelos, separe dados e ajuste transformações apenas no treino; preserve um conjunto final de teste.

04 LABORATÓRIO APLICADO

Laboratório aplicado revisado — Previsão temporal com corte cronológico e baseline

Corte cronológico, janelas somente com passado e baseline ingênuo são necessários antes de avaliar LSTM para séries.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

```
import numpy as np
from sklearn.linear_model import Ridge
from sklearn.metrics import mean_absolute_error
rng=np.random.default_rng(19);n=190;t=np.arange(n)
series=.03*t+np.sin(t/5)+rng.normal(0,.14,n)
k=6
X=np.array([series[i-k:i] for i in range(k,n)])
y=np.array([series[i] for i in range(k,n)])
cut=int(.75*len(X));Xt,Xe=X[:cut],X[cut:];yt,ye=y[:cut],y[cut:]
model=Ridge(alpha=1).fit(Xt,yt)
mae_model=mean_absolute_error(ye,model.predict(Xe))
mae_naive=mean_absolute_error(ye,Xe[:,-1])
print('MAE Ridge:',round(mae_model,3),'MAE último valor:',round(mae_naive,3),'teste ↪
    posterior ao treino:',cut)
assert X.shape[0]==len(y)
```

Separação temporal não substitui validação rolling-origin. A comparação com persistência é essencial; prever série sintética não comprova previsão financeira.

Checklist: conferir entradas e saídas, sementes, inexistência de uso dos dados de teste durante ajuste e distinção entre uma demonstração sintética e desempenho em aplicações reais.

05 EXERCÍCIO E SOLUÇÃO COMENTADA

Por que embaralhar indiscriminadamente uma série temporal pode causar vazamento?

Resposta: Porque amostras futuras podem influenciar treinamento e pré-processamento relativos ao passado.

LIMITAÇÕES E BOAS PRÁTICAS

- Confundir ajuste no treino com generalização para dados não vistos.
- Reportar somente uma métrica ou uma execução aleatória.

• Ignorar shape, tipo de variável e convenção do backend.

• Executar exemplos com pesos baixados sem registrar versão, licença e procedência.

• Confundir demonstração matemática com validação de um modelo de produção.

VERIFICAÇÃO LOCAL

Execute Reiniciar kernel e executar todas as células. Registre versões do Python e das dependências, confira shapes e métricas e diferencie os laboratórios opcionais dos exemplos NumPy/scikit-learn. Treinamentos TensorFlow/Keras não foram validados nesta geração editorial.

REFERÊNCIAS TÉCNICAS

NumPy: numpy.org/doc · scikit-learn: scikit-learn.org/stable/user_guide.html · Keras: keras.io/guides · TensorFlow: tensorflow.org/guide