GUIA TÉCNICO

Modelos sequenciais: séries temporais e sentimentos

Capítulo 19/20 · Fundamentos, experiência reproduzível e interpretação

PROPÓSITO E OBJETIVOS

- Construir janelas temporais sem vazamento e diferenciar modelagem temporal de classificação de textos.
- Relacionar a técnica à sua função de perda, representação e protocolo de avaliação.
- Explicar limitações e formular um teste reprodutível.

MAPA DE ESTUDO

1. Fundamentação do método
2. Expressões e hipóteses
3. Experimento essencial executável
4. Laboratório aplicado e limitações
5. Exercício e verificações

01 FUNDAMENTAÇÃO CONCEITUAL

Janelas dependem de horizonte, contexto e data de corte. Em séries financeiras, retornos não são previsíveis apenas por suavidade aparente; comparar com baseline ingênuo e evitar extrapolação de evidência. Em sentimento, tokenização e embeddings são requisitos (ver área de Processamento de Linguagem Natural).

Fonte histórica de apoio: notas do curso original, consultadas apenas como referência de contexto; as explicações e exemplos desta edição são independentes.

Questões críticas: quais pressupostos são necessários? O que a função aprende? Qual métrica indica utilidade real? Que tipo de vazamento ou má interpretação invalidaria a conclusão?

02 MATEMÁTICA E DIMENSÕES

Expressão esquemática: $X_t=(y_{t-k},\ldots,y_{t-1})$

A expressão acima resume a relação central. Para a derivação, identifique dimensões, hipóteses e operações; não interprete notação compacta como uma implementação completa.

LEITURA CRÍTICA DO CAPÍTULO

Corte cronológico, janelas somente com passado e baseline ingênuo são necessários antes de avaliar LSTM para séries.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

03 EXPERIMENTO ESSENCIAL

Código extraído do notebook revisado. Execute a célula completa no JupyterLab; as quebras visuais abaixo não substituem o arquivo executável.

```
import numpy as np
serie=np.arange(25,dtype=float)
janela=4;horizonte=1
X=np.array([serie[i:i+janela] for i in range(len(serie)-janela-horizonte+1)])
y=np.array([serie[i+janela+horizonte-1] for i in range(len(X))])
corte=round(.75*len(X));print('Treino:',X[:corte].shape,'teste:',X[corte:].shape,'primeiro
    alvo:',y[0]);assert y[0]==4.
```

INTERPRETAÇÃO

Compare o resultado obtido com a formulação matemática. Confirme shapes, escala e hipótese de modelagem. Um experimento sintético valida uma operação, não substitui avaliação em dados

reais. Ao treinar modelos, separe dados e ajuste transformações apenas no treino; preserve um conjunto final de teste.

04 LABORATÓRIO APLICADO

Laboratório aplicado revisado — Previsão temporal com corte cronológico e baseline

Corte cronológico, janelas somente com passado e baseline ingênuo são necessários antes de avaliar LSTM para séries.

Procedimento: execute a próxima célula com o núcleo declarado em requirements.txt, confira os assert e interprete os resultados. O experimento é independente dos exemplos anteriores.

```
import numpy as np
from sklearn.linear_model import Ridge
from sklearn.metrics import mean_absolute_error
rng=np.random.default_rng(19);n=190;t=np.arange(n)
series=.03*t+np.sin(t/5)+rng.normal(0,.14,n)
k=6
X=np.array([series[i-k:i] for i in range(k,n)])
y=np.array([series[i] for i in range(k,n)])
cut=int(.75*len(X));Xt,Xe=X[:cut],X[cut:];yt,ye=y[:cut],y[cut:]
model=Ridge(alpha=1).fit(Xt,yt)
mae_model=mean_absolute_error(ye,model.predict(Xe))
mae_naive=mean_absolute_error(ye,Xe[:,-1])
print('MAE Ridge:',round(mae_model,3),'MAE último valor:',round(mae_naive,3),'teste ↪
    posterior ao treino:',cut)
assert X.shape[0]==len(y)
```

Separação temporal não substitui validação rolling-origin. A comparação com persistência é essencial; prever série sintética não comprova previsão financeira.

Checklist: conferir entradas e saídas, sementes, inexistência de uso dos dados de teste durante ajuste e distinção entre uma demonstração sintética e desempenho em aplicações reais.

05 EXERCÍCIO E SOLUÇÃO COMENTADA

Por que embaralhar indiscriminadamente uma série temporal pode causar vazamento?

Resposta: Porque amostras futuras podem influenciar treinamento e pré-processamento relativos ao passado.

LIMITAÇÕES E BOAS PRÁTICAS

- Confundir ajuste no treino com generalização para dados não vistos.
- Reportar somente uma métrica ou uma execução aleatória.

- Ignorar shape, tipo de variável e convenção do backend.
- Executar exemplos com pesos baixados sem registrar versão, licença e procedência.
- Confundir demonstração matemática com validação de um modelo de produção.

VERIFICAÇÃO LOCAL

Execute Reiniciar kernel e executar todas as células. Registre versões do Python e das dependências, confira shapes e métricas e diferencie os laboratórios opcionais dos exemplos NumPy/scikit-learn.

Validação posterior (13/11/2026): notebooks 14 a 20 executados com TensorFlow CPU; opcionais 01 a 13 não integralmente revalidados.

REFERÊNCIAS TÉCNICAS

NumPy: numpy.org/doc · scikit-learn: scikit-learn.org/stable/user_guide.html · Keras: keras.io/guides · TensorFlow: tensorflow.org/guide

REVISÃO DIDÁTICA · CAPÍTULO 19

Séries temporais: horizonte e fronteira temporal

1. Conceito, escopo e interpretação

Séries temporais exigem respeito à ordem temporal em treino, validação e teste. Sentimentos são sequências textuais, mas exigem tokenização, vocabulário aprendido apenas no treino e métrica adequada a classes.

2. Formalização e exemplo resolvido

Em previsão com janela k, features_t=[y_(t-k),...,y_(t-1)] e alvo=y_t. Baseline persistência: y_hat_t=y_(t-1). MAE=media(abs(y_t-y_hat_t)).

3. Relação com o notebook e experimento

No notebook compare Ridge com previsão de persistência usando corte cronológico. Confira se cada janela usa somente observações anteriores ao alvo e se a normalização é ajustada apenas no passado.

4. Limitações e erros frequentes

Shuffle aleatório pode vazar informação futura. Treinar em janelas muito sobrepostas e avaliar janelas adjacentes tende a superestimar independência; considere horizonte e dados de implantação.

5. Exercício comentado

Para prever y_10 com janela de 3 passos, quais valores são permitidos? y_7,y_8,y_9. Usar y_10 ou qualquer y posterior nas features é vazamento.

6. Ampliação conceitual do guia

A previsão exige preservar a ordem temporal. Para um horizonte h, cada janela de entrada usa apenas observações disponíveis antes do alvo. Em séries com tendência ou sazonalidade, compare sempre um baseline ingênuo (último valor ou sazonal).

7. Orientação de estudo e validação

O notebook emprega corte cronológico, Ridge e erro absoluto médio. Um split aleatório pode usar implicitamente o futuro para prever o passado. A parte de sentimento exige outra definição de dados, tokenização e métricas; não se deve confundir experimento de regressão temporal com classificação de texto.

8. Exercício adicional de fixação

Exercício: treino até dezembro e teste em janeiro é apropriado? Resposta: sim, se as features de janeiro não contiverem observações posteriores ao instante previsto.

Verificação: execute o notebook homônimo no ambiente apropriado; registre versões, shapes, sementes e métricas. Laboratórios Keras opcionais não foram executados durante esta revisão documental.

Abrir notebook do capítulo no repositório