ONNX, inferência visual e modelos modernos

ONNX

Formato
Intercâmbio de grafos computacionais.

Modelo
Não é arquitetura neural em si.

Runtime
Executa operadores compatíveis.

ENTRADA

Layout
NCHW ou NHWC conforme o modelo.

Canais
RGB/BGR na ordem esperada.

Escala
Normalização do pipeline de treino.

INFERÊNCIA

Carregar
Sessão de execução opcional.

Shape
Conferir assinaturas de entrada e saída.

Pós-processar
Converter logits/boxes de forma adequada.

EXPERIMENTO

Simulação
Array de imagem e medição de tempo.

Real
Requer modelo ONNX e runtime instalados.

Saída
Não confundir mock com inferência real.

LATÊNCIA

Média
Σt_i / n em repetidas medições.

Warmup
Aquecer antes da coleta.

Justiça
Mesmo hardware e tamanho de entrada.

CHECKLIST

Conferir
Versão de operadores e modelos.

Medir
Média e dispersão, com repetição.

Registrar
Ambiente, parâmetros e limitações.