GUIA TÉCNICO

Fundamentos de Visão Computacional

Distinguir processamento, descrição, detecção, classificação, localização e reconhecimento.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Erros comuns e limitações
8. Consulta rápida
9. Aprofundamento v2 — auditoria e aplicação
10. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Distinguir processamento, descrição, detecção, classificação, localização e reconhecimento.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

Um pixel não é um objeto: imagens são medições discretas da luz. O problema visual depende de aquisição, domínio, rótulos, resolução, iluminação e custo de erro. Um pipeline inclui aquisição → pré-processamento → características → inferência → avaliação. Distinga classificação de imagem inteira, detecção de objetos com caixas, segmentação por pixel e reconhecimento de indivíduos.

Conceito matemático

$$I \in \mathbb{R}^{H \times W \times C}$$

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
from sklearn.datasets import load_digits
import numpy as np
D=load_digits()
I=D.images.astype('float32')/16
print('n imagens:',len(I),'shape de cada:',I.shape[1:],'classes:',len(np.unique(D.target)))
assert I.min()>=0 and I.max()<=1
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import matplotlib.pyplot as plt
fig,axes=plt.subplots(1,5,figsize=(10,2))
for ax,i in zip(axes,range(5)):
 ax.imshow(I[i],cmap='gray',vmin=0,vmax=1);ax.set_title(f'Dígito {D.target[i]}');ax.axis('off')
plt.tight_layout();plt.show()
```

Interpretação técnica

Os dígitos já estão alinhados e em baixa resolução: boa demonstração, mas não representam ambientes visuais reais.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: Por que uma boa acurácia em dígitos não garante sucesso no reconhecimento de caracteres em fotografias?

Resolução comentada: Porque aquisição, perspectiva, fundo, luz e ruído alteram a distribuição; a generalização depende do domínio.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Erros comuns e limitações

Não use uma base didática limpa para prometer desempenho em ambientes reais.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Distinguir processamento, descrição, detecção, classificação, localização e reconhecimento.
- **Mecanismo:** Um pixel não é um objeto: imagens são medições discretas da luz.
- **Equação:** $I\in\mathbb{R}^{H\times W\times C}$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: tarefa e ground truth. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **tarefa e ground truth** pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **tarefa e ground truth** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

A tarefa determina o tipo de rótulo necessário: classificação usa uma classe por imagem; detecção associa classes e caixas; segmentação requer máscaras por pixel. A referência de avaliação (ground truth) precisa representar a mesma tarefa e ter convenção de anotação consistente.

Interpretação e generalização

Um classificador de dígitos previamente recortados não mede desempenho de um detector em fotografias. Uma aplicação real exigiria localização, normalização do recorte, classificação e avaliação do pipeline completo, incluindo imagens negativas.

Atividade de consolidação

Construa uma tabela comparando classificação, detecção e segmentação quanto a entrada, saída, métrica e erro mais custoso. Indique um exemplo de ground truth válido para cada tarefa.