GUIA TÉCNICO

Limiarização, segmentação e componentes conectados

Segmentar objetos e extrair medidas geométricas com critérios explícitos.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Erros comuns e limitações
8. Consulta rápida
9. Aprofundamento v2 — auditoria e aplicação
10. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Segmentar objetos e extrair medidas geométricas com critérios explícitos.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

Segmentação gera rótulos ou máscaras para regiões da imagem. Otsu escolhe limiar maximizando separabilidade entre classes de intensidade; funciona pior quando iluminação varia espacialmente. Componentes conectados permitem contagem, área e caixas delimitadoras. Avaliar segmentação exige métricas como IoU e Dice com máscara de referência.

Conceito matemático

$$IoU(A,B)=/(|Acap B|)(|Acup B|)$$

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
from skimage.data import coins
from skimage.filters import threshold_otsu
from skimage.measure import label,regionprops
from skimage.morphology import remove_small_objects
img=coins();binary=img>threshold_otsu(img)
binary=remove_small_objects(binary,max_size=59)
regions=regionprops(label(binary))
print('componentes:',len(regions),'maiores áreas:',sorted([r.area for r in regions],
    reverse=True)[:5])
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import matplotlib.pyplot as plt
fig,ax=plt.subplots(1,2,figsize=(9,3))
ax[0].imshow(img,cmap='gray');ax[0].set_title('Original')
ax[1].imshow(binary,cmap='gray');ax[1].set_title('Máscara — não é GT')
for a in ax:a.axis('off')
plt.tight_layout();plt.show()
```

Interpretação técnica

O número de componentes não equivale necessariamente ao número de moedas; objetos unidos e reflexos quebram essa hipótese.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: Se uma predição tem 40 pixels de interseção e 60 de união com o gabarito, qual IoU?

Resolução comentada: 40/60 = 0,667.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Erros comuns e limitações

Não interpretar máscaras automáticas como verdade-terreno.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Segmentar objetos e extrair medidas geométricas com critérios explícitos.
- **Mecanismo:** Segmentação gera rótulos ou máscaras para regiões da imagem.
- **Equação:** $IoU(A,B)=\frac{|A\cap B|}{|A\cup B|}$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: componentes e topologia. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **componentes e topologia** pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Laboratório adicional — Contagem de componentes e efeito do limiar

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

```
import numpy as np
from skimage.measure import label
x=np.zeros((8,8),dtype=bool);x[1:3,1:3]=1;x[5:7,5:7]=1
componentes=label(x,connectivity=1)
print('Objetos separados:',int(componentes.max()))
assert componentes.max()==2
```

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **componentes e topologia** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

A limiarização converte intensidades em uma decisão binária. Otsu escolhe o limiar pela distribuição de valores, mas a separação pode falhar quando iluminação varia espacialmente ou o histograma não distingue bem objeto e fundo.

Interpretação e generalização

Componentes conectados dependem da convenção de vizinhança (4 ou 8 em duas dimensões). Uma única conexão diagonal pode mudar a contagem quando a conectividade escolhida muda. Área e perímetro também dependem da resolução.

Atividade de consolidação

Desenhe duas regiões que tocam apenas na diagonal e conte componentes sob conectividade 4 e 8. Compare com uma segmentação real antes de decidir qual definição de objeto é apropriada.