GUIA TÉCNICO

SVM, reconhecimento de caracteres e classificação visual

Treinar baseline de classificação visual com separação correta e matriz de confusão.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Erros comuns e limitações
8. Consulta rápida
9. Aprofundamento v2 — auditoria e aplicação
10. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Treinar baseline de classificação visual com separação correta e matriz de confusão.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

Reconhecimento de caracteres em imagem exige segmentação/alinhamento e classificador, ou sistemas de OCR fim a fim. SVM busca margem máxima com penalização de erros e pode consumir descritores como HOG. Comparar pixels achatados e HOG; definir validação antes de seleção. Não confundir OCR de caracteres isolados com leitura de documentos.

Conceito matemático

min_(w,b)/12|w|^2+CΣ_ixi_i

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
from sklearn.datasets import load_digits
from sklearn.model_selection import train_test_split
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score,confusion_matrix
D=load_digits();a,b,ya,yb=train_test_split(D.data,D.target,test_size=.25,random_state=42,
    stratify=D.target)
clf=make_pipeline(StandardScaler(),SVC(kernel='rbf',C=2,gamma='scale')).fit(a,ya)
pred=clf.predict(b)
print('accuracy dígitos:',round(accuracy_score(yb,pred),3),'confusion shape:',
    confusion_matrix(yb,pred).shape)
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import matplotlib.pyplot as plt
from sklearn.metrics import ConfusionMatrixDisplay
ConfusionMatrixDisplay.from_predictions(yb,pred,cmap='Blues',colorbar=False,values_format='d')
plt.title('SVM — avaliação retida');plt.show()
```

Interpretação técnica

Erros entre dígitos visualmente semelhantes devem ser examinados individualmente.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: Por que separar treino e teste antes da seleção de hiperparâmetros?

Resolução comentada: Para evitar que o teste influencie as decisões de modelagem e gere desempenho otimista.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Erros comuns e limitações

Para OCR real, avaliar também sequência de caracteres e erros de transcrição por documento.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Treinar baseline de classificação visual com separação correta e matriz de confusão.
- **Mecanismo:** Reconhecimento de caracteres em imagem exige segmentação/alinhamento e classificador, ou sistemas de OCR fim a fim.
- **Equação:** $\min_{w,b}\frac12|w|^2+C\sum_i\xi_i$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: divisão por imagem/pessoa. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **divisão por imagem/pessoa** pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **divisão por imagem/pessoa** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

Uma SVM linear procura separar classes com margem controlada pelo parâmetro C. Kernels permitem fronteiras não lineares, mas exigem calibração e avaliação; escalonamento dos atributos altera a geometria das distâncias e deve integrar o pipeline.

Interpretação e generalização

A mesma pessoa ou o mesmo documento pode gerar várias imagens correlacionadas. Dividir aleatoriamente imagens do mesmo grupo entre treino e teste superestima a generalização; o agrupamento deve acontecer antes do ajuste do classificador.

Atividade de consolidação

Compare um baseline simples com SVM usando divisões adequadas ao objetivo. Reporte matriz de confusão por classe e descreva o efeito da normalização sem usar o conjunto de teste para selecionar C.