GUIA TÉCNICO

Eigenfaces, Fisherfaces e LBPH

Explicar reconhecimento facial clássico e demonstrar técnicas sobre dados não biométricos.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Erros comuns e limitações
8. Consulta rápida
9. Aprofundamento v2 — auditoria e aplicação
10. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Explicar reconhecimento facial clássico e demonstrar técnicas sobre dados não biométricos.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

Eigenfaces aplica PCA a imagens vetorizadas para encontrar direções de variância; Fisherfaces combina redução e discriminação supervisionada; LBPH resume padrões locais de textura em histogramas. Essas técnicas dependem de alinhamento, resolução e condições de captura. O laboratório utiliza dígitos como analogia matemática para não distribuir fotografias biométricas históricas.

Conceito matemático

Z=(X-mu)W_(PCA)

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
from sklearn.datasets import load_digits
from sklearn.decomposition import PCA
from sklearn.discriminant_analysis import LinearDiscriminantAnalysis
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
D=load_digits();a,b,ya,yb=train_test_split(D.data,D.target,stratify=D.target,random_state=4,
    test_size=.25)
pca=PCA(n_components=20,random_state=4).fit(a)
lda=LinearDiscriminantAnalysis().fit(pca.transform(a),ya)
print('PCA+LDA sobre dígitos (analogia):',round(accuracy_score(yb,
    lda.predict(pca.transform(b))),3),'variância PCA:',round(pca.explained_variance_ratio_.sum(),3))
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import matplotlib.pyplot as plt
fig,ax=plt.subplots(1,3,figsize=(9,3))
for a,img in zip(ax,pca.components_[:3]):a.imshow(img.reshape(8,8),cmap='coolwarm');a.axis('off')
plt.suptitle('Componentes PCA de dígitos — não são Eigenfaces');plt.tight_layout();plt.show()
```

Interpretação técnica

O experimento é analogia de PCA+LDA, não implementação de identificação biométrica. LBPH será discutido conceitualmente; requer cv2.face do OpenCV contrib para o módulo histórico.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: Qual principal diferença entre PCA e LDA?

Resolução comentada: PCA maximiza variância sem rótulos; LDA procura direções discriminativas entre classes.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Erros comuns e limitações

Não tratar componentes PCA de dígitos como eigenfaces reais, nem fornecer dataset facial sem licença.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Explicar reconhecimento facial clássico e demonstrar técnicas sobre dados não biométricos.
- **Mecanismo:** Eigenfaces aplica PCA a imagens vetorizadas para encontrar direções de variância; Fisherfaces combina redução e discriminação supervisionada; LBPH resume padrões locais de textura em histogramas.
- **Equação:** $Z=(X-\mu)W_{PCA}$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: divisão por identidade. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **divisão por identidade** pode produzir conclusões enganosas. Indique um indicador observável, um

teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **divisão por identidade** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

Eigenfaces projeta imagens em um subespaço obtido por PCA, priorizando direções de variação. Fisherfaces busca direções discriminativas por LDA. LBPH usa padrões locais de intensidade e agrega histogramas em regiões.

Interpretação e generalização

Esses métodos dependem fortemente de alinhamento, iluminação e qualidade dos recortes. PCA e LDA devem ser ajustados exclusivamente ao treino; separar imagens por identidade ou sessão depende da pergunta de avaliação.

Atividade de consolidação

Mostre em um conjunto didático a dimensão original, a dimensão projetada e a métrica de classificação. Explique por que o experimento em dígitos é uma analogia metodológica e não validação de reconhecimento facial.