GUIA TÉCNICO

CNNs e transferência de aprendizado em classificação visual

Comparar convoluções aprendidas, baselines clássicos e inferência pré-treinada.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Laboratório opcional — requer dependência extra
8. Erros comuns e limitações
9. Consulta rápida
10. Aprofundamento v2 — auditoria e aplicação
11. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Comparar convoluções aprendidas, baselines clássicos e inferência pré-treinada.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

CNNs aprendem filtros por retropropagação; transfer learning reutiliza representações treinadas em outro domínio. O congelamento de camadas diminui o custo inicial, mas o domínio de origem pode ser inadequado. A teoria de backpropagation e arquitetura CNN já foi desenvolvida na Disciplina 07; aqui a ênfase é no pipeline de visão e no desenho experimental.

Conceito matemático

$$F_{out}=\sigma(K*I+b)$$

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
import numpy as np
from skimage.data import camera
from scipy.signal import convolve2d
img=camera().astype(float)/255
kernel=np.array([[1,0,-1],[2,0,-2],[1,0,-1]])/4
filtered=convolve2d(img,kernel,mode='same',boundary='symm')
print('Filtro de borda (fixo, não treinado):',filtered.shape,'média absoluta:',
    round(abs(filtered).mean(),4))
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import matplotlib.pyplot as plt
fig,ax=plt.subplots(1,2,figsize=(9,3))
ax[0].imshow(img,cmap='gray');ax[0].set_title('Imagem')
ax[1].imshow(filtered,cmap='gray');ax[1].set_title('Kernel fixo — demonstração')
for a in ax:a.axis('off')
plt.tight_layout();plt.show()
```

Interpretação técnica

Este filtro fixo não é uma CNN treinada; sua função é esclarecer a operação. Treinamento com Keras fica no laboratório opcional dependente de TensorFlow.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: O que significa congelar um backbone pré-treinado?

Resolução comentada: Manter os pesos do extrator fixos enquanto se aprende inicialmente uma nova cabeça de classificação.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Laboratório opcional — requer dependência extra

Não execute esta parte sem verificar a instalação e a memória disponível. O bloco abaixo está em texto de código para consulta; pode ser copiado para uma célula nova quando o ambiente estiver preparado.

```
# Opcional — somente com TensorFlow já instalado e recursos suficientes
import tensorflow as tf
model=tf.keras.Sequential([
 tf.keras.Input(shape=(32,32,3)),
 tf.keras.layers.Conv2D(8,3,activation='relu'),
 tf.keras.layers.MaxPooling2D(),
 tf.keras.layers.Flatten(),
 tf.keras.layers.Dense(2,activation='softmax')])
model.summary()
```

Erros comuns e limitações

Não descarregar automaticamente ImageNet nem reutilizar imagens sem licenças conferidas.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Comparar convoluções aprendidas, baselines clássicos e inferência pré-treinada.
- **Mecanismo:** CNNs aprendem filtros por retropropagação; transfer learning reutiliza representações treinadas em outro domínio.
- **Equação:** $F_{out}=\sigma(K*I+b)$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: fine tuning e vazamento. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **fine tuning e vazamento** pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **fine tuning e vazamento** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

Uma convolução com kernel fixo mostra um operador linear local, não o treinamento de uma CNN. Em redes convolucionais, pesos são ajustados por otimização; transfer learning exige um backbone realmente pré-treinado e política explícita de congelamento.

Interpretação e generalização

Ao ajustar um modelo, o conjunto de teste permanece intocado. Data augmentation precisa ser aplicado somente ao treino; no fine-tuning, taxa de aprendizado baixa e controle de camadas atualizadas ajudam a evitar esquecimento do pré-treino.

Atividade de consolidação

Separe três cenários: filtro fixo, CNN treinada do zero e backbone pré-treinado. Para cada um indique o que é aprendido, quais pesos mudam, a origem dos dados e a métrica apropriada.