GUIA TÉCNICO

ONNX, inferência visual e modelos modernos

Distinguir treino, exportação e inferência, e validar metadados de entradas e saídas.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Laboratório opcional — requer dependência extra
8. Erros comuns e limitações
9. Consulta rápida
10. Aprofundamento v2 — auditoria e aplicação
11. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Distinguir treino, exportação e inferência, e validar metadados de entradas e saídas.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

ONNX é formato de intercâmbio de grafos computacionais, não arquitetura de rede. O pipeline de inferência exige shape (N,C,H,W) ou (N,H,W,C), normalização, ordem dos canais, pós-processamento e versões de operadores compatíveis. Comparar latência exige warmup, repetição, mesmo hardware e precisão numérica. Sem runtime instalado, validaremos a lógica com NumPy.

Conceito matemático

$$\text{latência média} = \frac{1}{n}\sum_{i=1}^{n} t_i$$

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
import numpy as np,time
rng=np.random.default_rng(1)
img=rng.integers(0,256,(64,64,3),dtype=np.uint8)
x=img.astype('float32')/255.0
nchw=np.transpose(x,(2,0,1))[None]
assert nchw.shape==(1,3,64,64)
print('BGR/RGB precisa ser definido; entrada NCHW:',nchw.shape,'dtype:',nchw.dtype)
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import numpy as np
# Demonstração de validação de saída; NÃO equivale a inferência ONNX.
logits=np.array([1.0,2.4,-0.2]);scores=np.exp(logits-logits.max());scores/=scores.sum()
print('Softmax sintético:',np.round(scores,3),'classe:',int(scores.argmax()))
assert np.isclose(scores.sum(),1)
```

Interpretação técnica

O exemplo implementa só preparo e pós-processamento; ONNX Runtime não é exigido e nenhum modelo foi carregado.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: Se o modelo espera RGB mas recebe BGR, a inferência é equivalente?

Resolução comentada: Não: a semântica dos canais muda e o desempenho pode degradar.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Laboratório opcional — requer dependência extra

Não execute esta parte sem verificar a instalação e a memória disponível. O bloco abaixo está em texto de código para consulta; pode ser copiado para uma célula nova quando o ambiente estiver preparado.

```
# Opcional com onnxruntime e modelo ONNX autorizado, já disponível localmente:
# import onnxruntime as ort
# session=ort.InferenceSession('modelo_validado.onnx',providers=['CPUExecutionProvider'])
# print([(i.name,i.shape,i.type) for i in session.get_inputs()])
```

Erros comuns e limitações

Uma API de inferência precisa preservar exatamente o pré-processamento usado no treinamento.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Distinguir treino, exportação e inferência, e validar metadados de entradas e saídas.
- **Mecanismo:** ONNX é formato de intercâmbio de grafos computacionais, não arquitetura de rede.
- **Equação:** $latência\ média=\frac{1}{n}\sum_{i=1}^n t_i$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: dependência ONNX. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **dependência ONNX** pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **dependência ONNX** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

ONNX descreve um grafo computacional interoperável. A inferência real requer modelo existente, operadores suportados e um runtime compatível; conversão de forma NHWC para NCHW e normalização devem seguir o contrato do modelo.

Interpretação e generalização

Uma aplicação de softmax em logits sintéticos demonstra processamento de saída, mas não constitui inferência ONNX. Antes de medir latência, considere aquecimento, tamanho do lote, dispositivo, sincronização e número de repetições.

Atividade de consolidação

Registre as formas, dtypes e nomes de entrada e saída de uma sessão válida. Meça tempos repetidos e a dispersão; se o arquivo de modelo não existir, registre o teste como não executado.