GUIA TÉCNICO

Avaliação, robustez, privacidade e reprodutibilidade

Auditar métricas, drift, grupos, licenças e documentação de sistemas visuais.

Propósito — servir como material autoral de estudo aprofundado e referência com exemplos, atividades e integração com os notebooks.

Como utilizar — acompanhe os conceitos, reproduza os exemplos em ambiente apropriado e compare hipóteses antes de concluir.

ROTEIRO DO DOCUMENTO

1. Objetivos de aprendizagem
2. Fundamentos conceituais
3. Experimento 1 — construção e medidas
4. Experimento 2 — visualização, comparação ou validação
5. Interpretação técnica
6. Exercício resolvido
7. Erros comuns e limitações
8. Consulta rápida
9. Aprofundamento v2 — auditoria e aplicação
10. Aprofundamento técnico orientado ao capítulo

Objetivos de aprendizagem

Auditar métricas, drift, grupos, licenças e documentação de sistemas visuais.

Ao concluir, você deverá ser capaz de **explicar a técnica**, **executar o exemplo**, **interpretar limitações** e **justificar escolhas de avaliação**.

Fundamentos conceituais

Avaliar classificação com confusion matrix, macro-F1 e intervalos de confiança; detecção com IoU, precision/recall e AP quando houver anotações adequadas. Distribuições distintas e populações sub-representadas podem reduzir desempenho. Para faces, considerar finalidade legítima, consentimento, governança e retenção mínima de dados. Separar pessoas ou sessões relacionadas entre treino/teste quando aplicável.

Conceito matemático

$$F_1=/(2PR)(P+R)$$

A fórmula expressa o mecanismo principal do capítulo. Identifique unidades, dimensões e hipóteses antes de aplicar uma implementação.

Experimento 1 — construção e medidas

Execute em kernel limpo. Exemplos usam datasets de bibliotecas instaláveis e não requerem download de arquivos externos.

```
from sklearn.metrics import classification_report,confusion_matrix
import numpy as np
truth=np.array([0,0,0,0,1,1,1,1,1,1]);pred=np.array([0,0,0,1,0,1,1,1,0,1])
print(classification_report(truth,pred,zero_division=0))
print('Matriz:',confusion_matrix(truth,pred))
```

Experimento 2 — visualização, comparação ou validação

Observe não apenas o valor obtido, mas o que o experimento **realmente demonstra**.

```
import numpy as np
rng=np.random.default_rng(5)
correct=(truth==pred).astype(int)
samples=rng.choice(correct,size=(1000,len(correct)),replace=True).mean(axis=1)
print('Acurácia de exemplo:',round(correct.mean(),3),'IC bootstrap ilustrativo:',
    np.round(np.quantile(samples,[.025,.975]),3))
```

Interpretação técnica

Intervalo bootstrap didático com n pequeno não substitui protocolo de avaliação robusto; realizar avaliação de grupos somente com dados legítimos e adequados.

Conexão com o acervo

Em vez de repetir capítulos de SVM, PCA, métricas e backpropagation, este notebook concentra a aplicação e limitações **em imagens**. Revisite as Disciplinas 05 e 07 para demonstrações matemáticas mais extensas.

Exercício resolvido

Problema: Por que dividir fotos de uma mesma pessoa entre treino e teste pode ser inadequado?

Resolução comentada: Porque imagens correlacionadas geram vazamento e superestimam a generalização a identidades novas.

Para praticar: modifique um parâmetro do exemplo, registre a hipótese antes de executar e compare resultado, qualidade visual e custo computacional.

Erros comuns e limitações

Evitar alegar reconhecimento de emoção, caráter ou intenção a partir de aparência; essas inferências são frágeis e frequentemente injustificadas.

- Nunca ajustar parâmetros em cima do conjunto de teste final.
- Não confundir demonstração com validação científica completa.
- Documentar versões, fontes de dados e condições de execução.
- Não redistribuir fotografias de rostos ou datasets históricos sem licença e autorização.

Consulta rápida

- **Pergunta-chave:** Auditar métricas, drift, grupos, licenças e documentação de sistemas visuais.
- **Mecanismo:** Avaliar classificação com confusion matrix, macro-F1 e intervalos de confiança; detecção com IoU, precision/recall e AP quando houver anotações adequadas.
- **Equação:** $F_1=\frac{2PR}{P+R}$
- **Verificação:** interpretar formato dos dados, hipótese e saída antes de utilizar em um projeto.

Referências de estudo

- Apresentações originais da disciplina (PDF consolidado).
- Documentação: scikit-image, OpenCV, scikit-learn, conforme o capítulo.
- Para CNNs: Keras.

Aprofundamento v2 — auditoria e aplicação

Ponto de atenção deste capítulo: privacidade e drift. Este complemento não substitui as seções e exemplos anteriores.

Verificação conceitual. Explique, com suas palavras, em qual etapa do fluxo de trabalho o tema **privacidade e drift** pode produzir conclusões enganosas. Indique um indicador observável, um teste mínimo e uma limitação do procedimento.

Exercício de extensão. Reproduza o experimento central deste notebook alterando **um parâmetro por vez**. Compare com uma linha de base simples, reporte a variação da métrica pertinente e justifique o resultado. Quando houver treino/teste, qualquer etapa que aprenda parâmetros deve usar apenas o treino.

Checklist de conclusão: (1) entradas identificadas; (2) sementes registradas; (3) saídas interpretadas; (4) premissas explicitadas; (5) dados originais não sobrescritos.

Laboratório adicional — Matriz de confusão e limitações de amostras

Experimento independente do estado das células anteriores. Use-o como verificação e explique seus limites; resultados em conjuntos sintéticos não são estimativas de desempenho real.

```
from sklearn.metrics import confusion_matrix, classification_report
y_real=[0,0,0,1,1,1];y_pred=[0,0,1,1,0,1]
print('Confusão:',confusion_matrix(y_real,y_pred).tolist())
print(classification_report(y_real,y_pred,zero_division=0))
print('Exemplo pequeno; não permite inferência sobre subgrupos demográficos')
```

Exercício resolvido — protocolo mínimo de validação

Enunciado. Proponha uma comparação para **privacidade e drift** sem contaminar a avaliação.

Solução orientadora. Defina uma hipótese falsificável, escolha um baseline simples, fixe uma divisão adequada ao problema, altere uma única decisão metodológica e compare métricas no conjunto reservado. Não transforme exemplos sintéticos em conclusões sobre populações reais. Documente a configuração e os casos de falha. Quando o tema não envolver predição, substitua o baseline por uma implementação de referência e compare correção, cobertura e custo.

APROFUNDAMENTO TÉCNICO ORIENTADO AO CAPÍTULO

Mecanismo e hipóteses

A matriz de confusão separa acertos e erros por classe; precisão, recall e F1 respondem a perguntas diferentes. Em conjuntos desbalanceados, acurácia isolada pode ocultar uma taxa elevada de falsos negativos.

Interpretação e generalização

Bootstrap quantifica variabilidade em condições específicas, mas amostras correlacionadas não devem ser tratadas como independentes. Em sistemas com rostos, políticas de consentimento, minimização e retenção dos dados são parte do desenho experimental.

Atividade de consolidação

Calcule precisão, recall e F1 a partir de uma matriz pequena e compare com as funções do scikit-learn. Depois discuta um erro operacional mais grave e o possível impacto de mudanças no domínio.